Хеш-таблицы

Хеширование

С хешированием мы сталкиваемся очень часто: при работе с браузером (список Web-ссылок), текстовым редактором и переводчиком (словарь), языками скриптов (Perl, Python, PHP и др.), компилятором (таблица символов).

По словам Брайана Кернигана, это «одно из величайших изобретений информатики».

Заглядывая в адресную книгу, энциклопедию, алфавитный указатель, мы даже не задумываемся, что упорядочение по алфавиту является не чем иным, как хешированием.

Хеширование:

- разбиение множества ключей (однозначно характеризующих элементы хранения (в виде строк или чисел) на непересекающиеся подмножества (наборы элементов), обладающие определенным свойством.

Это свойство описывается **хеш-функцией**, и называется **хеш-адресом.**

Решение обратной задачи возложено на хеш-структуры **(хеш-таблицы**): по хеш-адресу они обеспечивают быстрый доступ к нужному элементу.

В идеале для задач поиска **хеш-адрес** должен быть **уникальным**, чтобы за одно обращение получить доступ к элементу,который характеризуется заданным ключом (**идеальная хеш-функция**). Однако, на практике идеал приходится заменять компромиссом и исходить из того, что получающиеся наборы с одинаковым хеш-адресом содержат более одного элемента.

Хеш-таблицы и коллизии

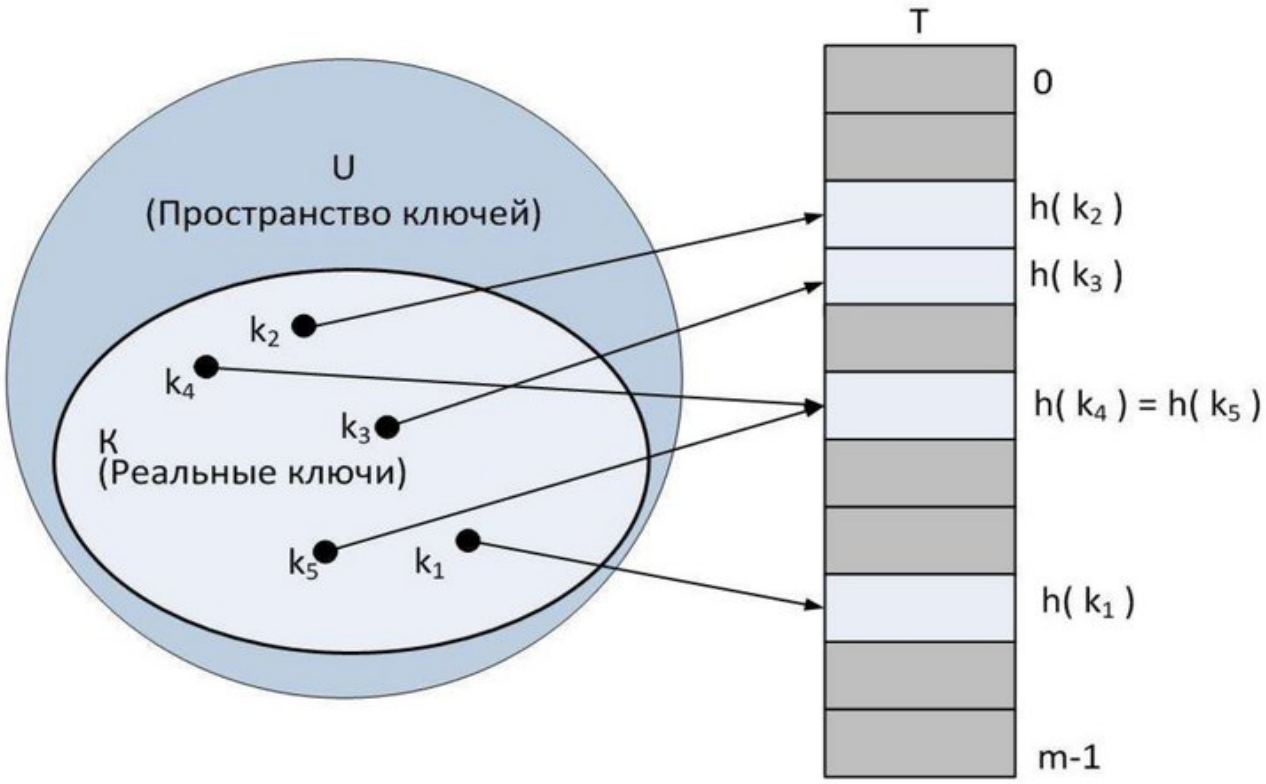

Коллизия – ситуация, когда два ключа хешированы в одну и ту же ячейку

хеш-функция

Эффективность использования деревьев для поиска информации – $O(\log_2 n)$.

Если функция по значению ключа сразу определяет индекс элемента массива хранения информации, то это функция, по которой можно вычислить этот индекс. Такая функция называется **хеш-функцией** (от to hash - крошить, рубить) и она ставит в соответствие каждому ключу (a_i) индекс ячейки (j) – хеш-адрес, где расположен элемент с этим ключом:

- **$h(a_i) = j$,** если j=(1,M),

- т. е. **j** принадлежит множеству от 1 до M,

где M - размер массива.

Т.О**. эффективность O(1)! Не зависит от разметов таблицы**

Простое представление ХЕШ- таблиц

Пусть необходимо сформировать библиотеку.

Есть 2 пути:

1.Расставить все книги по алфавиту (по автору или названию), создать картотеку соответствия книги и ее местоположения. Пользоваться картотекой при поиске нужной книги.

2.Создать некую функцию, которая исходя из названия книги будет ***вычислять*** местоположение определенной книги с помощью хеш-функции. Ключом поиска в данном случае будет выступать название книги.

Требования к хеш-функции

Хеш-функция должна иметь следующие свойства:

- Всегда возвращать один и тот же адрес для одного и того же ключа;
- Не обязательно возвращать разные адреса для разных ключей (не идеальная);
- Использовать все адресное пространство с одинаковой вероятностью;
- Быстро вычислять адрес.

хеш-таблица

Массив, заполненный в порядке, определенным хеш-функцией - это хеш-таблица. (процесс - хеширование)

Т.О. хеш-таблица – это стр-ра данных вида «ассоциативный массив», которая ассоциирует ключи со значениями.

Идеально: хеш–адрес уникален для значения, тогда сложность:

O(1)!!! и НЕ зависит

от размерности набора данных.

Иначе возникает **коллизия** (конфликт): один хеш–адрес для разных ключей.

Хеширование предполагают 2 этапа:

- построение хеш-таблицы, используя хеш-функцию;
- использование хеш-таблицы для поиска

Создание таблиц.

Метод деления (модульный)

В качестве хеш-функции используется **остаток от деления** ключа (K) на M:

$$h(K) = K \bmod M \qquad h(K) = K \,\%\, M$$

при N < M, где N – количество ключей, M – размер массива

M - Простое число!

Данная функция очень проста, хотя и не самая лучшая.

Вообще, для количества ключей равного **31** при размерности массива **41** можно создать $\mathbf{41^{31} \sim 10^{50}}$ хеш-функций, т. е. поиск хорошей хеш-функции - достаточно сложная задача!

Критерии «хорошей» хеш-функции

Хорошей является хеш-функция, удовлетворяющая условиям:

1. д. б. простой с вычислительной точки зрения (быстрой);
2. должна распределять ключи в хеш-таблице наиболее равномерно;
3. должна создавать минимальное число коллизий

Пример: ключи целые числа (8 элементов)

ключи: 25, 19, 07, 34, 16, 61, 44, 81

- массив M=11 (M – ближайшее б***О***льшее простое число)
- 25 % 11 = 3
- 19 % 11 = 8
- 07 % 11 = 7….

индекс	0	1	2	3	4	5	6	7	8	9	10
ключ	44	34		25	81	16	61	07	19		

Для всех различных ключей различные индексы – бесконфликтная хеш-таблица

Метод умножения (мультипликативный)

Для мультипликативного хеширования используется следующая формула:

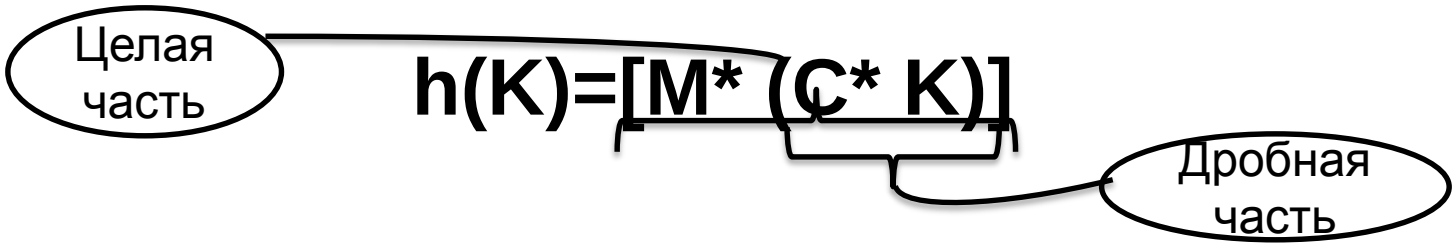

1. Умножение ключа **K** на константу **C**, лежащую в интервале [0..1]. (частн. случай (Кнут рекомендует): константа = значение золотого сечения $\varphi=(\sqrt{5}-1)/2 \approx 0{,}6180339887$).
2. Дробная часть этого выражения и умножается на константу **M**, выбранную т. о., чтобы результат не вышел за границы хеш-таблицы.
3. Оператор [ ] возвращает наибольшее целое, которое меньше аргумента.
4. Для с отрицательными числами можно число x взять по модулю.

От выбора M и C зависит то, насколько оптимальным окажется хеширование умножением на определенной последовательности. Не имея сведений о входящих ключах, в качестве M следует выбрать одну из степеней двойки, т. к. умножение на 2^m равносильно сдвигу на m разрядов, что компьютером производиться быстрее.

При таком C, хеш-коды распределяться достаточно равномерно, но многое зависит от начальных значений ключей.

Например, положим M=13, C=0,618033

Ключами возьмем числа: 25, 44 и 97.

Подставим их в функцию:

h(k)=⌊13*({25*0,618033})⌋=⌊13*{15,450825}⌋=⌊13*0,450825⌋=
⌊5,860725⌋=5

h(k)=⌊13*({44*0,618033})⌋=⌊13*{27,193452}⌋=⌊13*0,193452⌋=
[2,514876⌋=2

h(k)=⌊13*({97*0,618033})⌋=⌊13*{59,949201}⌋=⌊13*0,949201⌋=
⌊12,339613⌋=12

Метод сложения (аддитивный)

Модификация метода деления. Используется для строк переменной длины (сложение по модулю 256). Недостаток: YX = XY (коллизии)

Пример: ключи строковые

ключи: END, VAR, FOR, OR, AND, NIL, BEGIN

массив M=11 (11 – следующее после 7 простое число)

h (END) = (69 + 78 + 68) % 11 = 215 %11 = 6

h (VAR)= (86 + 65 + 82) % 11 = 233 % 11 = 2

h (FOR)= (70 + 79 + 82) % 11 = 231 % 11 = 0

h (OR)= (79 + 82) % 11 = 161 % 11 = 7

h (AND)=(65 + 78 + 68) % 11= 211 % 11 = 2

h (NIL)=(78 + 73 + 76) % 11 = 227 % 11 = 7

h (BEGIN)=(66 + 69 + 71 + 73 + 78) % 11 = 357 % 11 =5

индекс	0	1	2	3	4	5	6	7	8	9
ключ	FOR		VAR, END???			BEGIN	END	OR, NIL ???		

Коллизия – хеш-функция отражает 2 разных эл-та из более широкого множества в один и тот же эл-нт более узкого множества

Метод «исключающее ИЛИ»

Используется для строк переменной длины – аналогичен сложению, но дает разные ключи: XY != YX (последовательно применяется XOR к элементам строки)

В алгоритме добавляется случайная компонента (надо хранить!), чтобы еще улучшить результат (размер таблицы = 256):

For i←0 до длины слова

Sum ← sum + ord(st[i]) ***xor*** *random(255)*

H← sum mod 256;

Например. VA и AV

- V =86=1010110_2
- A =65=1000001_2
- 1) random(255) -1010_2
- 2) random(255) - 1011_2,
  - то:
- V+A=1010110_2 xor 1010 +1000001_2 xor 1011 =1011100+1001010 = ***10100110***

- V+A= 1000001_2 xor 1010 +1010110_2 xor 1011 =101011+1011101 = ***10010000***

метод середины квадрата

Один из самых очевидных и простых способов хеширования - **метод середины квадрата**:

- ключ возводится в квадрат и берется несколько цифр в середине. (предполагается, что ключ сначала приводится к целому числу, для совершения с ним арифметических операций). Метод хорошо работает до момента, когда нет большого количества нолей слева или справа.

Устранение коллизий

Метод цепочек

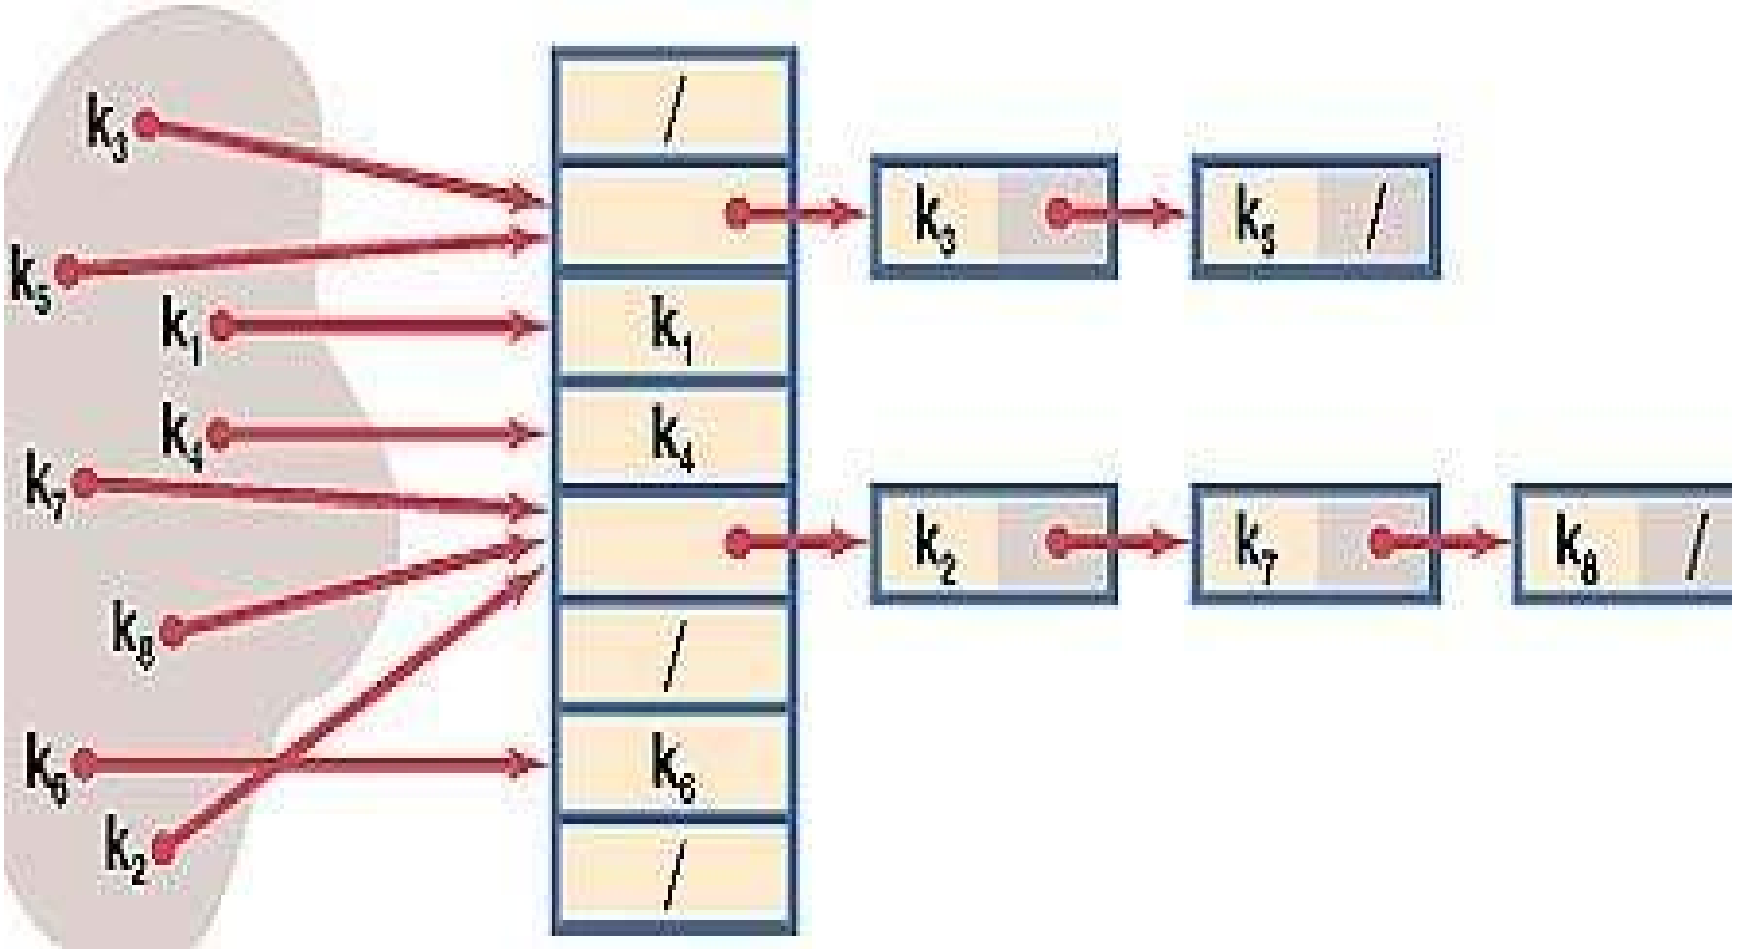

Метод цепочек
(открытое хеширование - внешнее)

- Данные хранятся не в самой таблице, а в связных списках. В таблице – ссылка на первый элемент списка
- Создается цепочка (список) элементов с одним ключом.
- Поиск в списке осуществляется простым перебором, т.к. при грамотном выборе хеш-функции любой из списков оказывается достаточно коротким.
- ключи: END, VAR, FOR, OR, AND, NIL, BEGIN
  - Основной недостаток - для узлов указателей требуется дополнительное пространство. рекомендуемый размер хеш-таблицы: M=N/2 (рекомендация Microsoft – 0.72*M)
  - В нашем случае: 9 сравнений на 7 ключей. В среднем 1.286 сравнений на поиск ключа

Метод цепочек

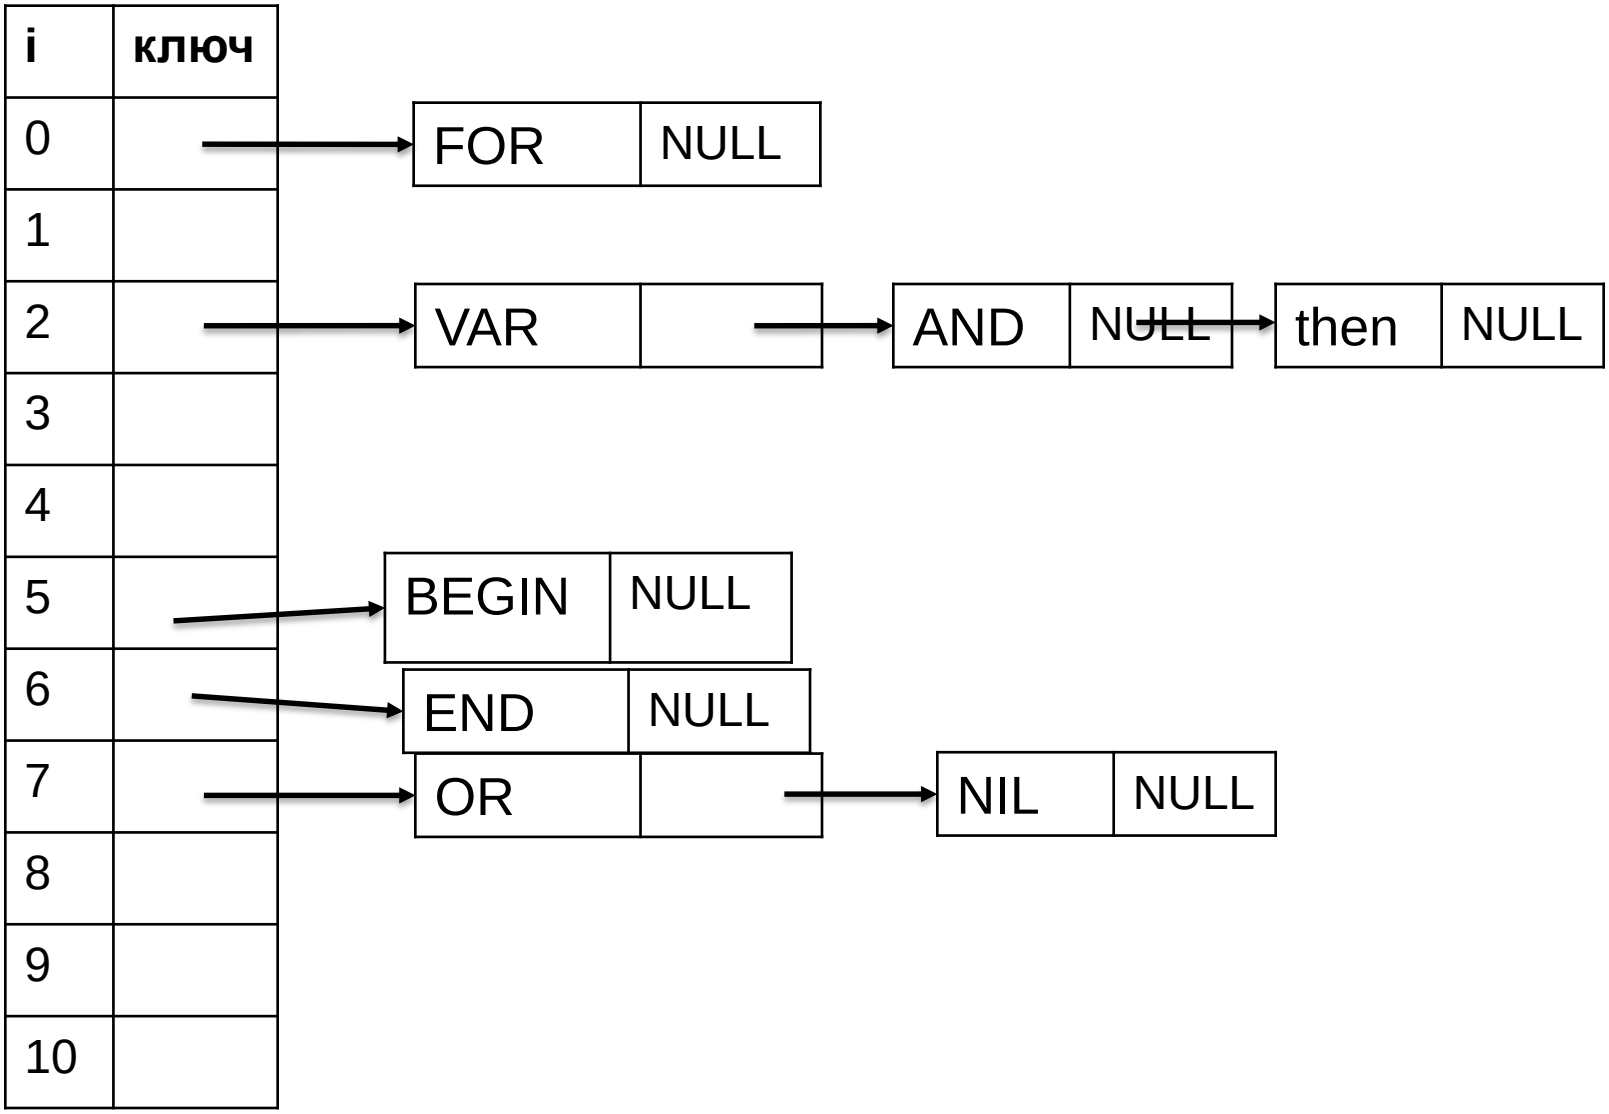

Метод цепочек

индекс	ключ	Указатель
0	FOR	Nil Nil
1		Nil Nil
2	VAR	начало конец
3		Nil Nil
4		Nil Nil
5	BEGIN	Nil Nil
6	END	Nil Nil
7	OR	начало конец
8		Nil Nil
9		Nil Nil

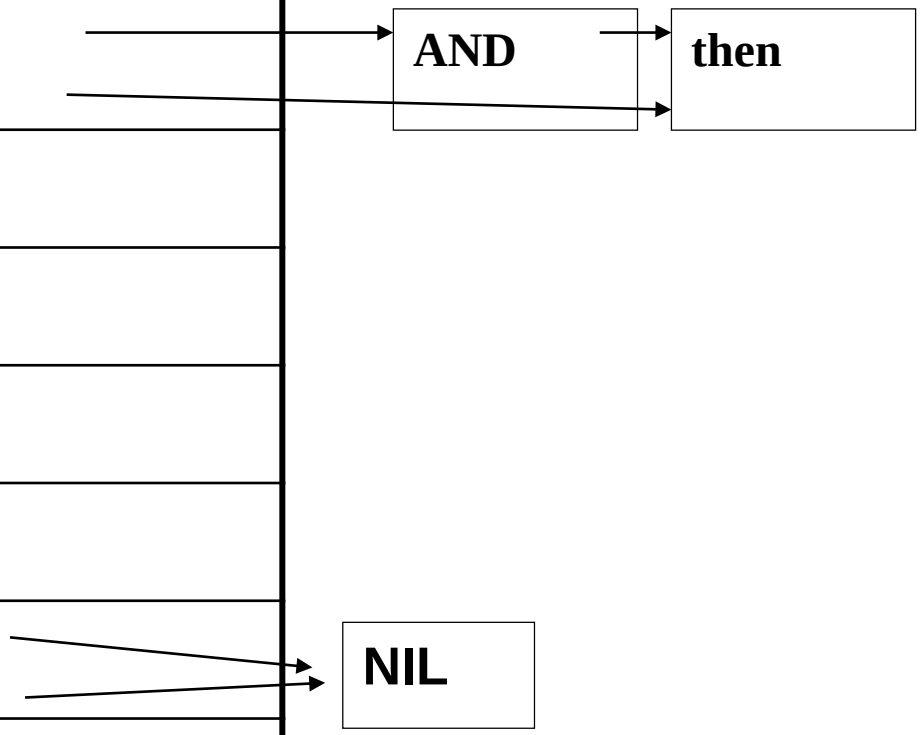

Закрытое хеширование
(внутреннее, открытая адресация)

1. Имеется изначально пустая хеш-таблица **T** размера **M**, массив **A** размера **N** (M≥N) и хеш-функция **h()**, пригодная для обработки ключей массива **A**;
2. Элемент $\mathbf{x_i}$, ключ которого $\mathbf{key_i}$, помещается в одну из ячеек хеш-таблицы, руководствуясь следующим правилом:
   a) если $\mathbf{h(key_i)}$ – номер свободной ячейки таблицы **T**, то в нее записывается $\mathbf{x_i}$;
   b) если $\mathbf{h(key_i)}$ – номер уже занятой ячейки таблицы **T**, то на занятость проверяется другая ячейка, если она свободна то $\mathbf{x_i}$ заноситься в нее, иначе вновь проверяется другая ячейка, и так до тех пор, пока не найдется свободная или окажется, что все **M** ячеек таблицы заполнены.

ключ	13	27	19	29	52	63	4	35	18	07
хеш-значение	2	5	8	7	8	8	4	2	7	7

+ 13, 27, 19, 29

i	ключ
0	
1	
2	13
3	
4	
5	27
6	
7	29
8	19
9	
10	

+ 52(2)

i	кл
0	
1	
2	13
3	
4	
5	27
6	
7	29
8	19
9	**52**
10	

+ 63(3)

i	кл
0	
1	
2	13
3	
4	
5	27
6	
7	29
8	19
9	52
10	**63**

+ 4(1)

i	кл
0	
1	
2	13
3	
4	**4**
5	27
6	
7	29
8	19
9	52
10	63

+ 35(2)

i	кл
0	
1	
2	13
3	**35**
4	4
5	27
6	
7	29
8	19
9	52
10	63

+ 18, 7(5,6)

i	кл
0	**18**
1	**7**
2	13
3	
4	4
5	27
6	
7	29
8	19
9	52
10	63

Среднее число сравнений для поиска 10 ключей:

Ключи 13, 27, 19, 29 ,4 по 1 сравнению

ключи 52, 35 по 2 сравнения

63 - 3 сравнения,

18 - 5 сравнений,

7 - 6 сравнений

Итого:

5 + 2*2 + 3 + 5 + 6 = 23

23 сравнений, т.е. в среднем 2,3 сравнения на один ключ.

Линейная адресация

(линейное исследование, linear probing), использует последовательность проверок, свободна ли ячейка с вычисл. индексом. Размер табл д.б. больше кол-ва ключей (M>N)

рекомендуемый размер хеш-таблицы: M=1.2*N

Алгоритм построения хеш-таблицы:

(Ячейки таблицы - TABL[i], где 0 ≤ i< M

N - количество занятых узлов)

1. Установить i=h(K)
2. Если TABL[i] пуст, то перейти к шагу 4, иначе, если по этому адресу искомый эл-нт, алгоритм завершается.
3. Установить i=i– 1, если i< 0, то i=i+M. Вернуться к шагу 2.
4. Вставка, т.к. поиск оказался неудачным. Если N=M– 1, то алгоритм завершается по переполнению. Иначе увеличить N, пометить ячейку TABL[i] как занятую и установить в нее значение ключа K.

- алгоритм хорошо работает в начале заполнения таблицы
- Пример: ключи целые (значение хеш)
- ключи: 15(4), 17(6), 19(8), 37(4), 5(5), 28(6) M=11

индекс	0	1	2	3	4	5	6	7	8	9
ключ					15	37	17	5	19	28

Среднее кол-во сравнений =
1 + 1 + 1 + 2 + 3 + 4= 12/6 = 2

\+ простота

\- «кучкование»

Квадратичная адресация:

$$h=h+ a^2,$$

где a – это номер попытки.

Этот вид адресации достаточно быстр и предсказуем (1, 4, 9, 16, 25, 36 и т.д.).

Чем больше коллизий, тем дольше этот путь.

- \+ хорошее распределение по таблице
- \- занимает больше времени для просчета.

Произвольная адресация:

использует заранее сгенерированный список случайных чисел для получения последовательности. Дает выигрыш в скорости, но несколько усложняет задачу программиста.

Недостатки метода открытой адресации *(закрытого хеширования)*

1) он предполагает фиксированный размер таблицы. Если число записей превысит этот размер, то их невозможно вставлять без выделения таблицы б***о***льшего размера и повторного вычисления значений хеширования для ключей всех записей, находящихся уже в таблице, используя новую хеш-функцию. (реструктуризация таблицы)

2) - из такой таблицы трудно удалить ключ (запись).

Адресация с двойным хешированием

- Используются две хеш-функции $h_1(K)$ и $h_2(K)$. Последняя должна порождать значения в интервале от 1 до M– 1, взаимно простые с M.

1. Установить $i=h_1(K)$
2. Если TABLE[i] пуст, то перейти к шагу 6, иначе, если по этому адресу искомый - завершение.
3. Установить $c=h_2(K)$
4. Установить i=i – c, если $i < 0$, то i=i +M.
5. Если TABLE[i] пуст, то переход на шаг 6. Если искомое расположено по этому адресу, то - завершение, иначе возвращаемся на шаг 4.
6. Вставка. Если N=M– 1, то алгоритм завершается по переполнению. Иначе увеличить N, пометить ячейку TABLE[i] как занятую и установить в нее значение ключа K.

- вариант дает значительно более хорошее распределение и независимые друг от друга цепочки. Но, он несколько медленнее из-за введения доп. функции.
- Д. Кнут предлагает несколько различных вариантов выбора доп. функции. Если M – простое число и $h_1(K) = K \bmod M$, то можно положить $h_2(K)=1 + (K \bmod (M – 1))$; но, если M нечетно, (для простых чисел - всегда), было бы лучше положить $h_2(K) = 1 + (K \bmod (M – 2))$.
- Здесь обе функции достаточно независимы.
- Г. Кнотт в 1968 предложил при простом M использовать функцию:
- $h_2(K)=1$, если $h_1(K)=0$ и
- $h_2(K)=M – h_1(K)$ в противном случае (т.е. $h_1(K) > 0$).
- Этот метод выполняется быстрее повторного деления, но приводит к увеличению числа проб из-за повышения вероятности того, что два или несколько ключей пойдут по одному и тому же пути.

Удаление элементов хеш-таблицы

- Очевидный способ удаления записей из закртытой хеш-таблицы не работает.
- Обрабатывать удаление можно, помечая элемент как удаленный, а не как пустой.
- Т. о. каждая ячейка в таблице будет содержать еще одно из трех значений: **пустая, занятая, удаленная**.
- При поиске - удаленные элементы будут трактоваться как занятые, а при вставке – как пустые, соответственно.

Задача №6Деревья, хеш –таблицы

- **Цель работы – построить дерево, вывести его на экран в виде дерева, реализовать основные операции работы с деревом: обход дерева, включение, исключение и поиск узлов, сбалансировать дерево, сравнить эффективность алгоритмов сортировки и поиска в зависимости от высоты деревьев и степени их ветвления; построить хеш-таблицу и вывести ее на экран, устранить коллизии, если они достигли указанного предела, выбрав другую хеш-функцию и реструктуризировав таблицу; сравнить эффективность поиска в сбалансированных деревьях, в двоичных деревьях поиска (ДДП), в хеш-таблицах и в файлах. Сравнить эффективность реструктуризации таблицы для устранения коллизий и поиска в ней с эффективностью поиска в исходной таблице.**

Динамическое хеширование

Предыдущие методы хеширования - статические, т.е. сначала выделяется некая хеш-таблица, под ее размер подбираются константы для хеш-функции.

Это не подходит для задач, в которых размер БД меняется часто и значительно.

По мере роста БД можно:

- пользоваться изначальной хеш-функцией, теряя производительность из-за роста коллизий;
- выбрать хеш-функцию «с запасом» - неоправданные потери дискового пространства;
- периодически менять функцию, пересчитывать все адреса - отнимает очень много ресурсов и выводит из строя базу на некоторое время.

Техника, позволяющая динамически менять размер хеш-структуры

Хеш-функция генерирует т. наз. псевдоключ (“pseudokey”), использующийся лишь частично для доступа к элементу: генерируется дост. длинная битовая последовательность, которая д. б. достаточна для адресации всех потенциально возможных элементов. При статическом хешировании для этого потребовалась бы очень большая таблица (которая обычно хранится в ОП для ускорения доступа), здесь размер занятой памяти прямо пропорционален количеству элементов в базе данных.

Каждая запись в таблице хранится не отдельно, а в каком-то блоке (“bucket”). Эти блоки совпадают с физическими блоками на устройстве хранения данных. Если в блоке нет больше места, чтобы вместить запись, то блок делится на два, а на его место ставится указатель на два новых блока.

Задача состоит в том, чтобы построить бинарное дерево, на концах ветвей кот. были бы указатели на блоки, а навигация осуществлялась бы на основе псевдоключа. Узлы дерева м. б. 2-х видов: узлы, показывающие др. узлы или узлы, показывающие блоки.

Например, пусть узел имеет такой вид, если он показывает на блок:

- Zero Null
- Bucket Указатель
- One Null

Если он будет показывать на два других узла (a, b), то он будет иметь такой вид:

- Zero Адрес **a**
- Bucket Null
- One Адрес **b**

- Вначале имеется указатель на динамически выделенный пустой блок. При добавлении элемента вычисляется псевдоключ, и его биты поочередно используются для определения местоположения блока.
- Например, элементы с псевдоключами 00… будут помещены в блок **A**, а 01… - в блок **B**. Когда **A** будет переполнен, он будет разбит т. о., что элементы 000… и 001… будут размещены в разных блоках (**A** и **D**).

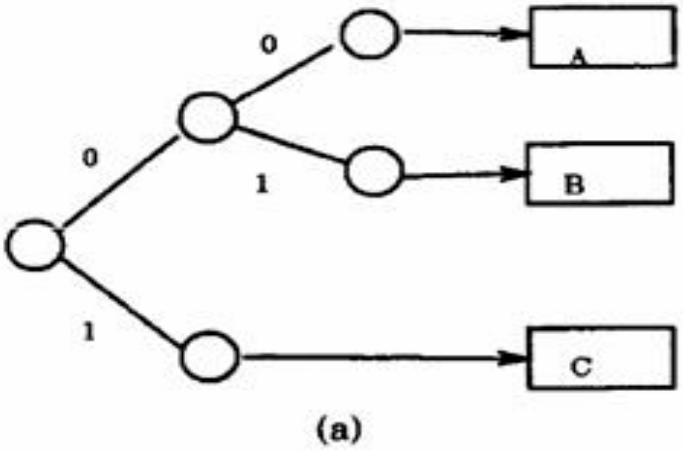

(a)

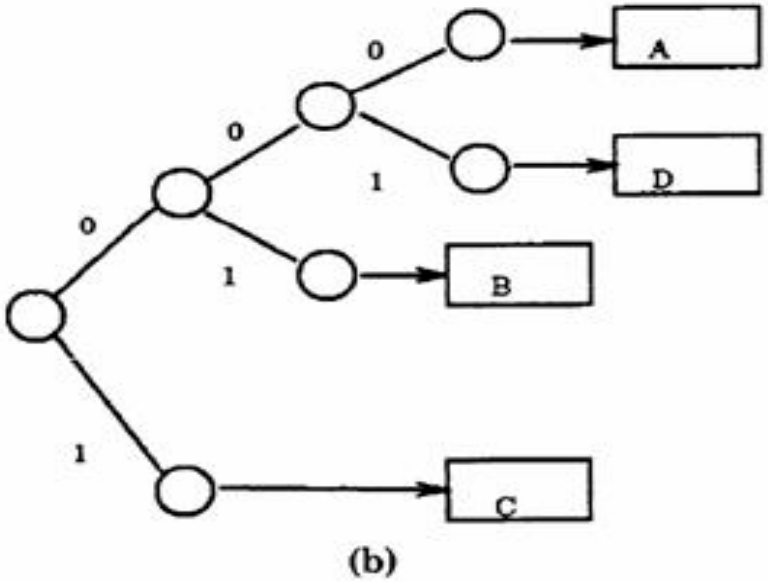

(b)

Расширяемое хеширование (extendible hashing)

Этот метод также предусматривает изменение размеров блоков по мере роста БД, но это компенсируется оптимальным использованием места, т.к. за один раз разбивается не более одного блока, накладные расходы достаточно малы.

Вместо бинарного дерева - список, элементы кот. ссылаются на блоки. Сами элементы адресуются по некоторому количеству ***i*** битов псевдоключа. При поиске берется ***i*** битов псевдоключа и через список (directory) находится адрес искомого блока. При добавлении элементов сначала выполняется процедура, аналогичная поиску. Если блок неполон, добавляется запись в него и в БД. Если заполнен, он разбивается на 2, записи перераспределяются по описанному выше алгоритму. В этом случае возможно увеличение числа бит, необходимых для адресации. Размер списка удваивается и каждому вновь созданному элементу присваивается указатель, который содержит его родитель. Т. о., возможно, когда несколько элементов показывают на один и тот же блок. (за одну операцию вставки пересчитываются значения не более, чем одного блока).

Удаление производится по такому же алгоритму, только наоборот. Блоки, соответственно, могут быть склеены, а список – уменьшен в два раза.

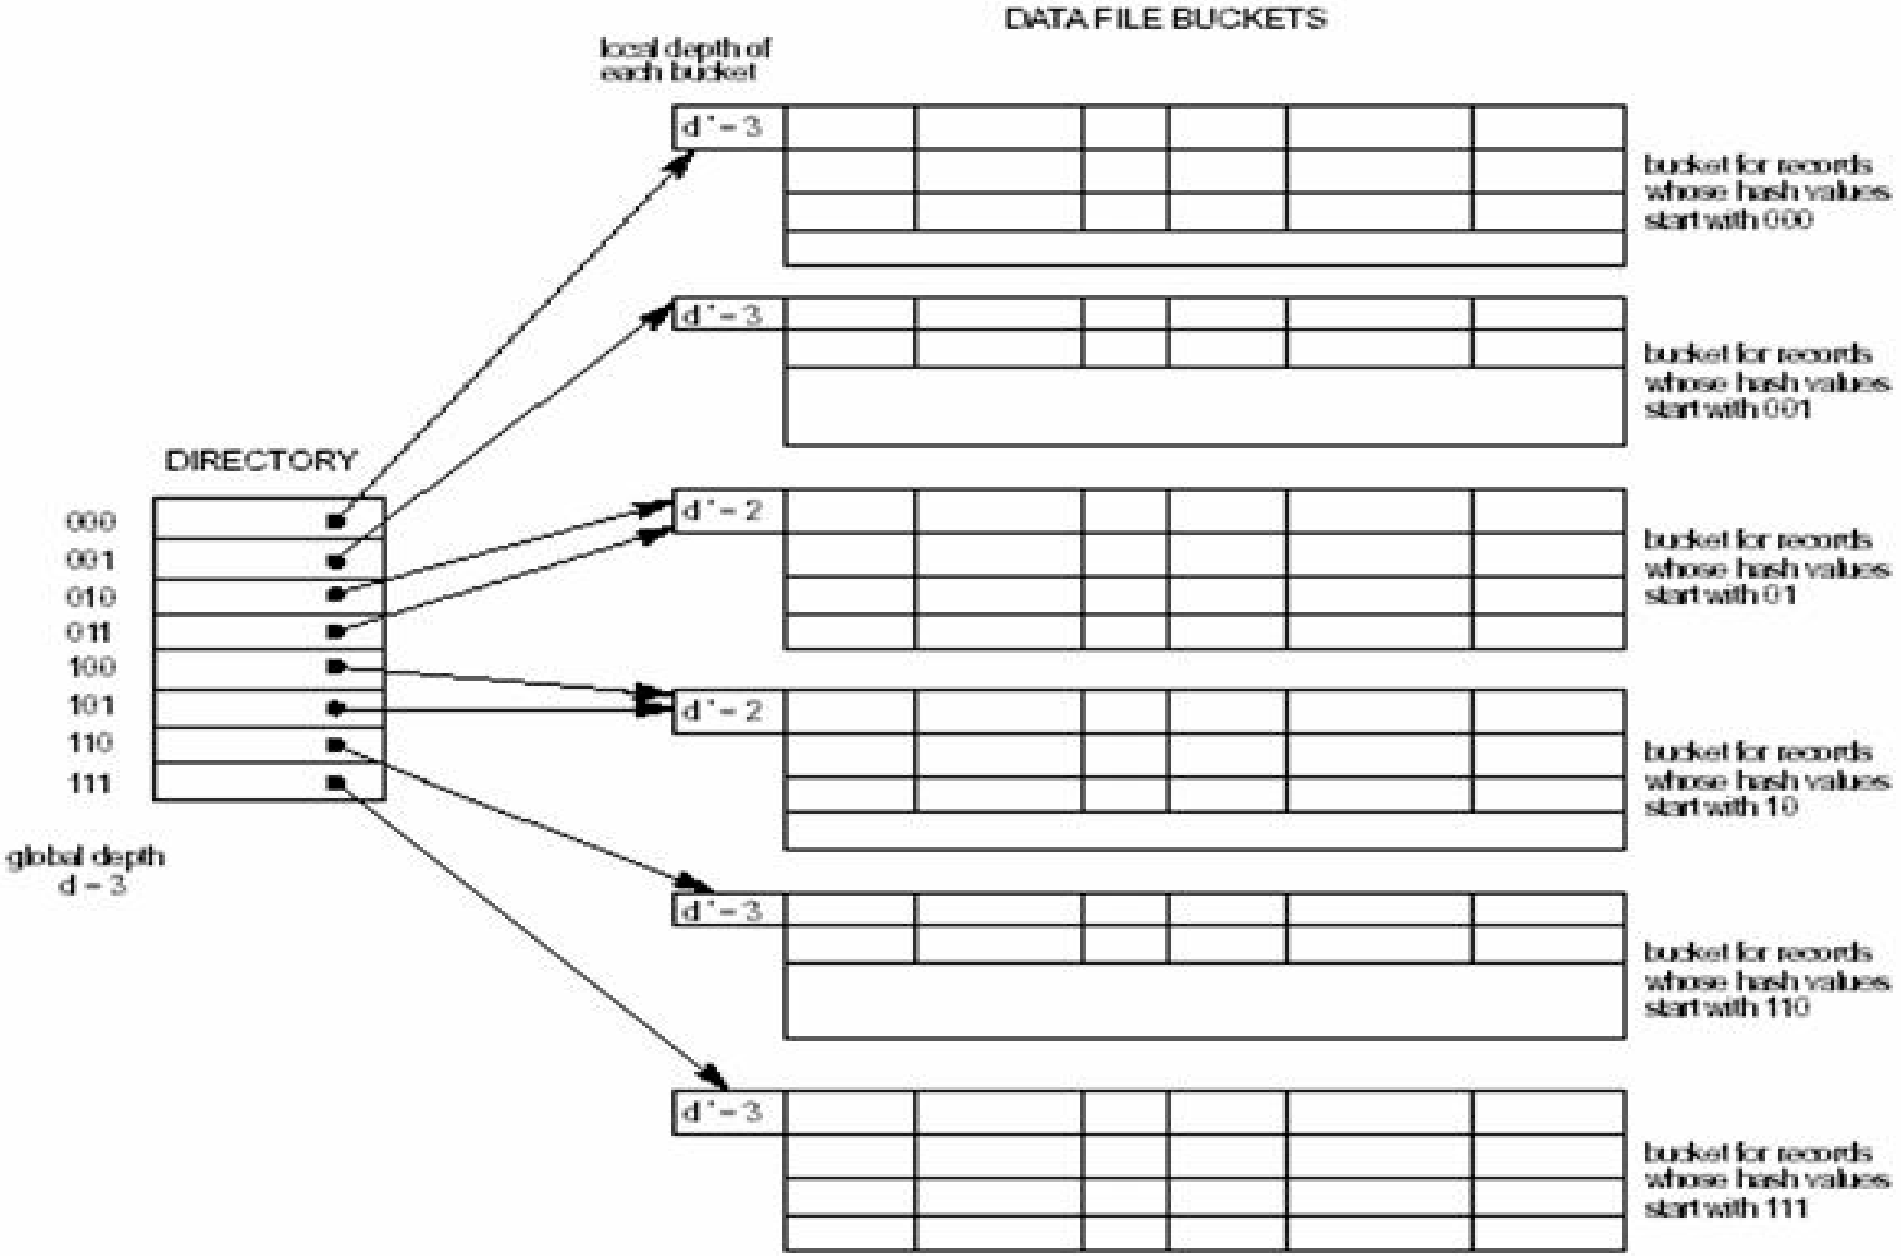
DATA FILE BUCKETS
local depth of each bucket
d' = 3
bucket for records whose hash values start with 000
d' = 3
bucket for records whose hash values start with 001
DIRECTORY
000
001
010
011
100
101
110
111
d' = 2
bucket for records whose hash values start with 01
d' = 2
bucket for records whose hash values start with 10
global depth d = 3
d' = 3
bucket for records whose hash values start with 110
d' = 3
bucket for records whose hash values start with 111

Рассмотрим это на примере

Хеш-таблица = каталог (directory), а каждая ячейка будет указывать на **емкость** (*bucket*) которая имеет определенную **вместимость** (capacity).

Глобальная глубина показывает сколько младших бит будут использоваться для того чтобы определить в какую емкость следует заносить значения. А из разницы локальной глубины и глобальной глубины можно понять сколько ячеек каталога ссылаются на емкость

Количество ссылающихся ячеек $K=2^{G-L}$ где G — глобальная глубина, L — локальная глубина.

Пусть есть хеш-таблица, где содержатся числа:

4	1**00**
6	1**10**
7	1**11**
10	10**10**
16	100**00**
22	101**10**
24	110**00**
31	111**11**

Глобальная глубина таблицы G=2,
локальные глубины
емкостей L1,Ll2, L3, L4 (=2),
вместимость емкостей = 3

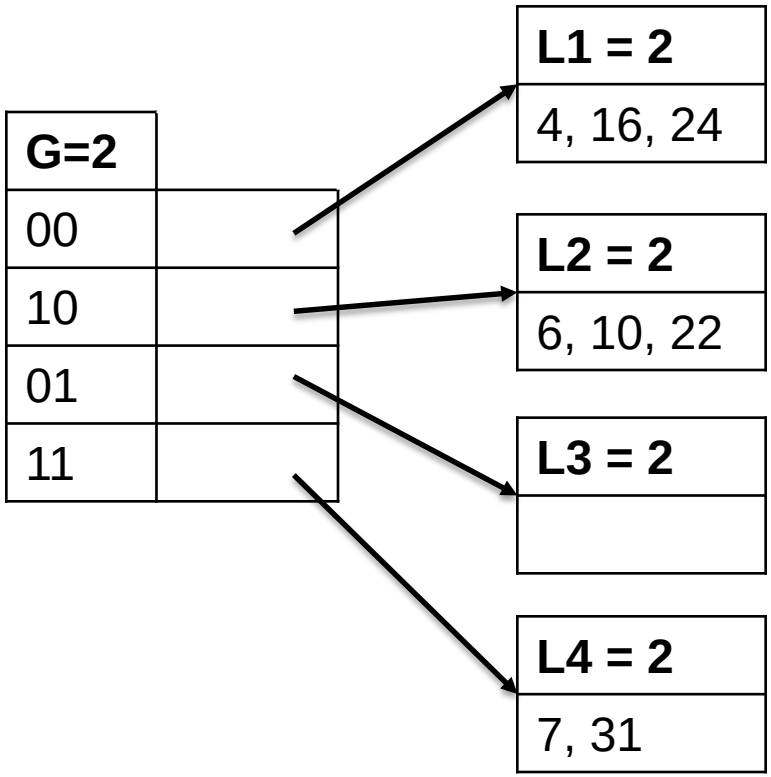

Мы хотим добавить в
этот каталог числа
9, 20, 26

Добавляем 9 (1001)

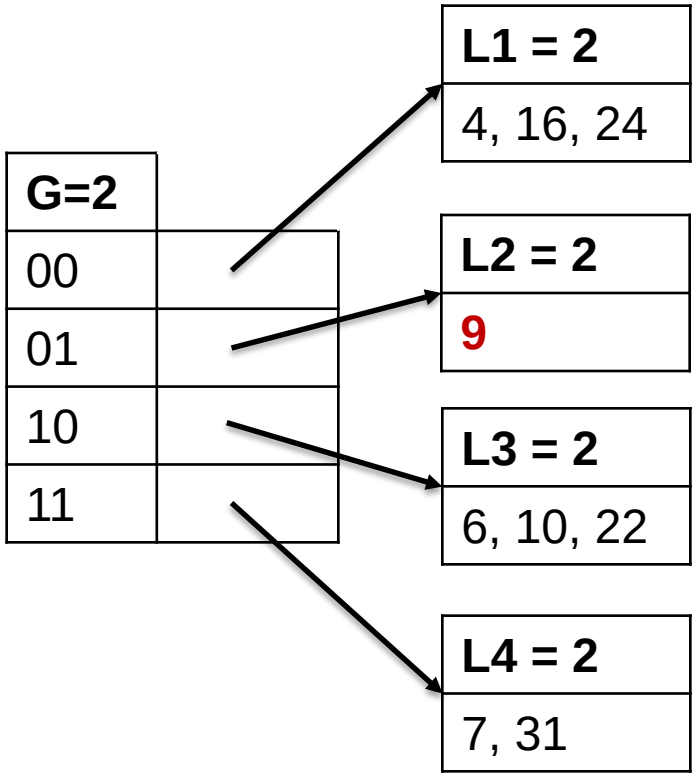

Добавляем 20 (10100)

Емкость 00 заполнена, L1=G

Удваиваем к-во ячеек каталога G=3

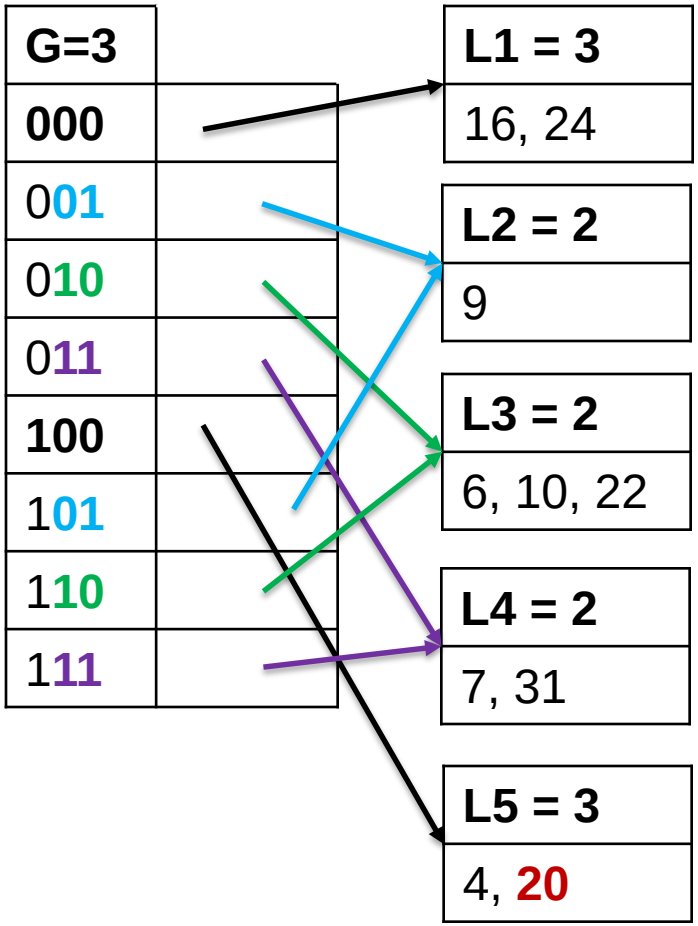

Далее на вход поступает 26 (11**010**)

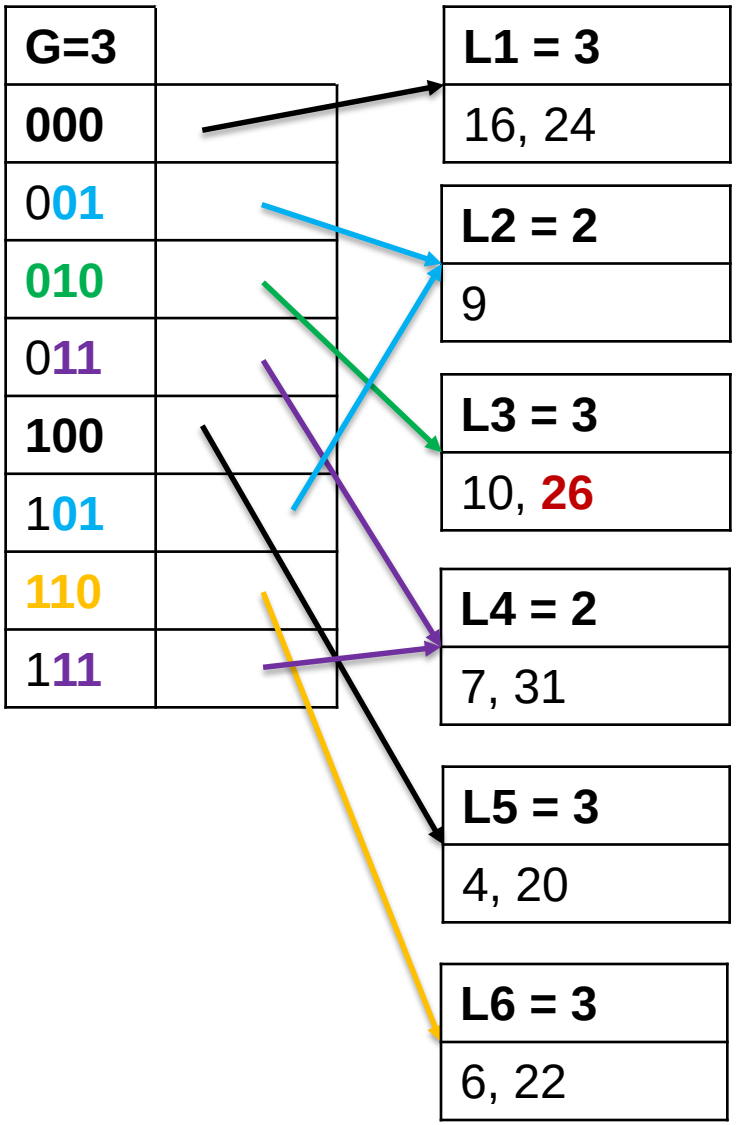

Последние 3 бита соответствуют емкости #3
Она заполнена.
При этом L3<G
Значит делим емкость на 2, увеличив локальную глубину,
Перехешируем значения емкости, распределив ее по новым емкостям.

Использование

Чаще всего расширяемое хеширование используется в базах данных так как:

- БД большие, при перехешировании всей БД доступа к базе нет на все время пересчета.
- При расширяемом хешировании перехешировать придется только малые группы, что не сильно замедлит работу базы данных.
- расширяемое хеширование хорошо работает в условиях динамически изменяемого набора записей в хранимом файле.

- Т.О., основное достоинство расширяемого хеширования - высокая эффективность, которая не падает при увеличении размера БД, разумное расходование места на устройстве хранения данных, т.к. блоки выделяются только под реально существующие данные, а список указателей на блоки имеет размеры, минимально необходимые для адресации данного кол-ва блоков.
- Расплата: разработчику приходится дополнительно усложнять программный код.

Применение хеширования

- Одно из побочных применений хеширования - создается своего рода слепок, «отпечаток пальца» для сообщения, текстовой строки, области памяти и т. п. Он может стремиться как к «уникальности», так и к «похожести» (яркий пример слепка — контрольная сумма CRC).
- В этом качестве применяется в криптографии. Здесь – особенности: скорость вычисления д.б. минимальна, а сложность восстановления максимальна.
- Соответственно необходимо затруднить нахождение другого сообщения с тем же хеш-адресом.
- В российском стандарте цифровой подписи используется хеш-функция (256 бит) стандарта
- ГОСТ Р 34.11—94.

Хеширование паролей

Напр., для шифрования используется 128-битный ключ. Хеширование паролей позволяет запоминать не 128 байт (т.е.256 16-ричных цифр), а некот. осмысленное выражение, слово или послед-ность символов, называющуюся паролем.

Существуют методы, преобразующие произносимую, осмысленную строку произвольной длины – пароль, в указанный ключ заранее заданной длины. Часто для этого используются хеш-функции. В данном случае хеш-функцией (Х-Ф) называется такое математическое или алгоритмическое преобразование заданного блока данных, обладающее след. свойствами:

- Х-Ф имеет бесконечную область определения,
- Х-Ф имеет конечную область значений,
- Х-Ф необратима,

Изменение входного потока информации на один бит меняет около половины всех бит выходного потока, то есть результата Х-Ф-ции

Эти свойства позволяют подавать на вход хеш-функции пароли, то есть текстовые строки произвольной длины на любом национальном языке и, ограничив область значений функции диапазоном $0..2^{N-1}$, где N – длина ключа в битах, получать на выходе достаточно равномерно распределенные по области значения блоки информации – ключи.

Еще пример

Пользователь вводит пароль, от него вычисляется хеш, сверяется с тем, что лежит в базе.

Например, хеш-функция MD5 применима к любому тексту и на выходе получает строку фиксированной длины 128 бит. Хеши для возможных паролей вычисляются такими:

MD5("fdgdgdh dfhfgh") = "1a503fd29bc6c64e1ffef9d0266b94e2"
MD5("qwerty") = "a86850deb2742ec3cb41518e26aa2d89"
MD5("Что такое хэш? Просьба написать упрощенно и незамысловато. ") = "7baaa6aab5d700abdd7b2d7d6eb23e9f"

Эта функция просто вычисляется лишь в одну сторону. Т. е. посчитать по строке ее хеш легко, а получить из хеша исходную строку - вычислительно сложно и - это соответствие неоднозначно, т.к. могут быть коллизии. Т.О. даже если получить доступ к к.-.л. базе данных, паролей на руках не окажется!.

- Хеш-функции обычно являются частью механизма электронно-цифровой подписи. Технология ЭЦП является современной заменой обычной бумажной подписи и часто удобнее её.
- Рост известности понятия ЭЦП вполне согласуется с явлением роста электронного документооборота.

- хеш-функции могут использоваться для обнаружения искажений при доставке сообщений по сетевым каналам, в качестве псевдослучайного генератора, для усовершенствования защиты от подмен и подделок документов.
- Хеш-функции могут использоваться в качестве генератора случайных чисел. Правда по скорости они будут уступать обычным.